

张弘毅

prince.fox.apple@gmail.com | (412)699-1699 | github.com/GiantPrince

教育经历

卡耐基梅隆大学	匹兹堡 美国
计算数据科学硕士, QPA: 4.19/4.33	2027.5
武汉大学	武汉 中国
计算机科学与技术本科 GPA: 3.98/4.00	2025.6

工作经历

亚马逊	西雅图 美国
软件开发工程师实习生	2026.5 - 2026.8
- 利用 Strands 为 Agent 测试框架开发验证网站是否符合 UX 设计稿的模块, 将原本耗时数小时的人工评估流程缩短至数分钟 - 设计并实现完整的图片存储与处理流程, 使用 Docker 容器化服务并通过 AWS CDK 完成基础设施部署; 实现并部署两个 Lambda 函数, 打通前端、S3、DynamoDB 与 ECS Fargate, 支持图片上传、存储及后续评估处理。 - 针对长图场景下评估准确率下降的问题, 设计长图分割算法, 引入图片对比子 Agent 以降低上下文占用, 并加入基于 Scratchpad 的中间推理机制, 使自定义评测数据集上的召回率提升约 20% - 为提升像素级设计差异的检测能力, 提出集成 Figma API 的元素启发式匹配方案, 利用更丰富的元数据补充 Agent 评估结果, 并生成可交互的 HTML 对比报告, 支持设计稿与前端效果的并排检查, 获得 UX 设计师的高度评价	

腾讯魔方工作室	深圳 中国
游戏客户端开发实习生	2024.6 - 2024.9
- 利用 Roslyn 开发 C# 代码转换工具, 并集成至团队热更新框架, 将原本耗时数分钟且需要多步操作的人工流程简化为一键式 workflow - 为了解决该工具在生产环境中生成代码要 20+秒的问题, 利用 Deep Profiler 工具定位了瓶颈在源代码文件的查找上, 于是利用项目的元数据作为索引极大地缩小了查找范围, 将时间降低至 1 秒左右 - 为了直接生成性能良好的代码, 扩展了该工具以自动生成支持缓存的代码减少重复的反射调用, 通过双向控制流同步, 结合跨过程读写依赖关系维护缓存一致性 - 开发了一款双人程序化动画游戏, 实现了巨型生物和简单的攀爬系统	

个人项目

Tirx 矩阵乘法优化	2026.4 - 2026.5
- 基于 TVM/TIRX 为 NVIDIA Blackwell GPU 实现高性能 FP16 GEMM Kernel, 在 8192³规模工作负载下实现接近 1.5 PFLOPS 的计算性能 - 围绕 Tensor Core 计算与显存访问进行深度优化, 综合采用 TMA、TMEM、异步 MMA、Tiling、软件流水线、Warp Specialization、Persistent Kernel 以及 Multi-CTA Clustering 等技术, 提升计算吞吐与硬件利用率	
Vulkan 实时渲染器 https://github.com/GiantPrince/MyViewer	2026.2 - 2026.5
设计并实现基于物理的 Vulkan 实时渲染管线, 支持 GPU 加速 IBL (Image-Based Lighting)、Cook-Torrance PBR、法线贴图, 阴影贴图, 多材质渲染以及色调映射的 HDR 渲染和 GPU 上的 AVBD 算法	
Unity 热更新框架优化 https://github.com/GiantPrince/Regulus	2025.2 - 2025.6
设计并实现兼容 CIL 的基于寄存器的中间语言与热更新框架, 实现了 SSA 优化、MSIL 注入及虚拟机, 相较 InjectFix 实现最高 79% 的性能提升。	

研究

RAG-Enhanced Commit Message Generation arxiv paper	2024.3 - 2024.5
共同设计基于 BM25 与 Transformer 的混合检索框架, 用于提升 Commit Message 自动生成效果; 在 CodeT5 和 Llama 3 上分别实现 BLEU 提升 55% 和 102%, 整体性能优于所有基线方法	
Review on LLM's KV-Cache Optimizations COLM 2024 paper (cited by 161)	2024.2 - 2024.3
系统调研多篇论文, 重点梳理 LLM 中的 KV Cache 优化策略	
Selective Prefix Tuning for Pre-trained Language Models ACL 2024 paper	2023.12 - 2024.2
提出 Selective Mask 与 Selective Loss, 在 SuperGLUE 上微调 BERT-base 和 BERT-large 超越 P-Tuning v2 1.4% 和 1.8%。	

技能

编程语言: C, C++, C#, Python, Java, Golang, Typescript
框架和工具: CUDA, Pytorch, Huggingface, Unity, Docker, Kubernetes, Helm, Vulkan